

Постановка задачи

В рамках работы была поставлена задача автоматизации процесса качественного анализа интервью, а именно: осуществление моделью разметки текста с выделением релевантных тематических кодов в заданном формате. В качестве обучающих и тестовых данных служили анонимизированные командой тексты интервью, полученные от Лаборатории молодежных исследований НИУ ВШЭ СПб.

Поскольку предполагается использование модели с данными Лаборатории, включающими конфиденциальную информацию об участниках исследований, модель должна быть компактной, чтобы работать локально на компьютерах Лаборатории. Кроме того, ограничением при обучении стали ресурсы бесплатного Google Colab. Модель должна быть обучена на русскоязычном корпусе, т.к. ЦМИ проводит исследования только в России.

Формат данных для теста:

Input: текст интервью, тема исследования

Output: разметка в формате «общий код: цитата (конкретный код)».

Обучающая выборка

149 анонимизированных интервью из лаборатории ВШЭ СПб “Центр молодежных исследований”. Интервью собраны в рамках различных исследований лаборатории. Все интервью являются глубинными, содержащими широкий спектр вопросов о респонденте и теме исследования. Длительность одного интервью составляет 1-1.5 часа. Одно интервью закодировано и размечено лабораторией в соответствии с внутренними стандартами.

Более подробный анализ данных предоставлен в файле `Eda_interviews.ipynb`

Выбор базовой модели

Изначально планировалось протестировать две модели: Qwen3.5-2B и DeepSeek-R1-Distill-Qwen-7B. Однако в процессе изучения документации и экспериментов выяснилось, что Qwen изначально выигрывает Deepseek за счет обучения на многоязычном корпусе с хорошим покрытием русского языка. Решающим фактором выбора стало наличие открытой архитектуры и стабильная работа в Google Colab.

Командой было решено проводить эксперименты с моделями семейства Qwen: с Qwen2.5-3B-Instruct и Qwen2.5-7B-Instruct.

Метрики оценки

BERTScore

Для автоматической оценки семантической близости использовался BERTScore. Метрика вычисляет косинусную близость контекстуальных эмбедингов токенов предсказанного и эталонного кодирования. Это позволяет оценивать смысловое соответствие, а не точное совпадение формулировок.

Оценка LLM

Для получения оценки LLM использовался вызов LLM через OpenRouter API. Оценка производилась по трем параметрам:

- Релевантность (0-1): соответствие кодов содержанию интервью
- Когерентность (0-1): грамматическая и стилистическая корректность
- Теоретический инсайт (0-1): глубина и концептуальная ценность кодов

Итоговая LLM-оценка вычислялась как среднее арифметическое трех параметров.

Комбинированный скор

Для итоговой оценки качества использовалась формула:

$$Combined = (BERTScore_F1 + LLM_Score)$$

Эксперименты с различными конфигурациями

В процессе поиска оптимальной архитектуры для задачи автоматического кодирования интервью был проведен ряд экспериментов с моделями семейства Qwen различных размеров и конфигураций. В поисках оптимального решения мы сравнивали следующие параметры моделей и ставили следующие предположения о работе модели при выборе определенного параметра:

Количество параметров модели: 3B и 7B

- большее число параметров позволяет “запомнить” больше абстрактных паттернов, таких как теоретическая релевантность, поэтому такая модель может быть точнее
- однако, при использовании большего количества параметров необходимо применять более жесткую квантизацию, что делает модель потенциально хуже из-за низкой точности в весах
- также, даже при применении квантизации 7B модель может не поместиться в доступные 15 Гб памяти в Google Colab

Промпт-инжиниринг

Поскольку команда располагает небольшим датасетом, в качестве настройки модели использовался промпт инжиниринг, так как он заключается в ручном изменении промпта без необходимости дообучения модели. К промпту был применен ChatTemplate, чтобы отделить системный промпт от пользовательского. В базовой версии промпта (hypothesis 0), в системной части на английском языке задается роль, задача и требования к ответу, а на русском языке подается пример выполненного кодирования: тема исследования, транскрипт интервью и разметка с кодами (референсный ответ модели), чтобы объяснить, в чем именно заключается задача модели. В пользовательской части модели задают тему исследования и транскрипт интервью на русском языке, чтобы на основе этого модель осуществила кодирование.

Мы тестируем несколько гипотез по изменению этого промпта для лучшего кодирования:

- H1: Системный промпт на русском языке устранил языковую путаницу, что улучшит качество модели
- H2: Добавление простой последовательной инструкции для выполнения кодирования (внимательно прочитать инструкцию – прочитать текст – выделить релевантные теме исследования цитаты – подобрать для них общие и конкретные коды – дать ответ строго по формату) разобьет сложную задачу модели на более простые, что улучшит качество модели
- H3: Удаление примера транскрипта из системного промпта и оставление только примеров кодирования для «понимания» структуры устранил цитирование текста из примера вместо пользовательского текста, что улучшит качество модели

Тип дообучения: LoRA fine tuning и PPO обучение с подкреплением

- LoRA - это стабильный и эффективный вариант дообучения в случае, если количество примеров достаточное, что может подойти под нашу задачу
- Фреймворк PPO позволяет использовать более близкие к поставленной задаче метрики в качестве награды, влияющей на обновление весов. Кроме того, есть возможность контролировать расхождение измененной и стабильной (reference) моделями с помощью расчета KL-дивергенции и ограничения обновлений с механизмом клиппинга

Квантизация: 4 бит и 8 бит

- более точная квантизация означает лучшую чувствительность модели к новым данным
- при использовании 4 бит квантизации, модель может стать значительно менее точной
- но в случае с 7 миллиардами параметров в модели, 4 бит квантизация может быть единственной, позволяющей использовать модель в Google Colab

Стратегия генерации: greedy search, beam search, доработанный beam search

- Beam Search (num_beams=5) как основа обеспечивает поиск наиболее вероятной последовательности
- repetition_penalty=1.5 штрафует генерацию токенов, которые уже встречались
- no_repeat_ngram_size=4 запрещает повторение 4-грамм (последовательностей из четырёх токенов)
- пост-обработка обеспечивает исключение дублирующихся строк и обрезание ответа после первого повторения
- дополнительные штрафы за повторения токенов сделают ответы более структурированными, не дадут модели “забыть” форму вопроса

Итоговый выбор моделей

Таким образом, мы осуществили обучение четырех моделей:

- Модель Qwen/Qwen2.5-3B-Instruct, дообученная с PPO с применением 8-битной квантизации, с размером батча 1
- Модель Qwen/Qwen2.5-3B-Instruct, дообученная с PPO с применением 4-битной квантизации, с размером батча 2
- Модель Qwen/Qwen2.5-3B-Instruct, дообученная с LoRA с применением 8-битной квантизации
- Модель Qwen/Qwen2.5-7B-Instruct, дообученная с LoRA с применением 4-битной квантизации

Также, мы посчитали метрики у модели Qwen/Qwen2.5-3B-Instruct с 8-битной квантизацией, взяв ее за бейзлайн, чтобы понять, будут ли дообученные нами модели лучше базовой.

Результаты

Сравнение работы модели и генерации ответа

Модели с использованием промпт инжиниринга показали качество хуже, чем при дообучении с LoRA.

Обе модели, дообученные с PPO, не попадают в форму ответа и генерируют местами связный текст. Вероятно, это связано с тем, что модель изменяется слишком часто, ввиду маленького размера батча, что привело к хаотичной генерации. Максимально консервативные параметры (низкий learning rate, высокий штраф за отход от reference model) привели к связности текста, но ни формат ответа, ни тем более теоретическую ценность ответов достичь этим способом не удалось.

Модель Qwen/Qwen2.5-3B-Instruct, дообученная с LoRA, показала семантически осмысленную генерацию кодов, наиболее похожую на референсное кодирование, которое было проведено лабораторией, а также “влезла” в Google Colab с применением 8-битной квантизации. Однако, модель имеет один недостаток: она меняет слова “конкретный код” и “общий код” на другие похожие слова. Но говоря в целом, с самой генерацией кодов модель, предположительно, справилась хорошо. Ниже мы сравним объективные метрики этой модели с другими в таблице.

Модель Qwen/Qwen2.5-7B-Instruct, дообученная с LoRA, поместилась на Google Colab только в условиях применения 4-битной квантизации, что, вероятно, сильно урезало ее качество, несмотря на количество параметров. На удивление, эта модель в качестве цитат выписывала огромные отрывки текста, которые содержали слишком много информации для одного кода, и в качестве кода не генерировала логическую тему, а просто использовала часть большой цитаты. Возможно, эта модель также имеет плохое качество из-за того, что она, в отличие от модели 3B, не смогла дообучиться полностью, так как не поместилась на GPU.

Поскольку большинство моделей не выдавали осмысленный текст, наибольшее значение имеет сравнение метрик для различных способов генерации модели с 3B параметрами и 8-битной квантизацией, обученной с LoRA.

Сравнение моделей на тестовой выборке с метриками

Сравнение конфигураций на тестовой выборке (23 интервью) с подсчетом метрик показало:

Базовая модель	Количество параметров	Квантизация, бит	Размер батча	Способ дообучения	Время на обучение	Стратегия генерации	BER TScore, тест	LLM score, тест	Общий скор
Qwen2.5	7B	4	Baseline	Baseline	Baseline	Beam search (5)	0.60	0.33	0.94
Qwen2.5	7B	4	Baseline	Baseline (prompt H1)	Baseline	Beam search (5)	0.55	0.32	0.87
Qwen2.5	7B	4	Baseline	Baseline (prompt H2)	Baseline	Beam search (5)	0.63	0.28	0.90
Qwen2.5	7B	4	Baseline	Baseline (prompt H3)	Baseline	Beam search (5)	0.62	0.57	1.19
Qwen2.5	3B	8	1	LoRA	1.5 ч	Greedy search	0.66	0.26	0.92

Qwen2. 5	3B	8	1	LoRA	1.5 ч	Beam search (5)	0.66	0.54	1.21
-------------	----	---	---	------	-------	-----------------------	-------------	-------------	-------------

Qwen2.5	3B	8	1	LoRA	1.5 ч	Улучшенный Beam search	0.68	0.40	1.08
Qwen2.5	7B	4	1	LoRA	1.5 ч	Greedy search	0.66	0.21	0.87
Qwen2.5	3B	4	2	PPO	1.5 ч	Sampling (t=0.5)	0.57	0.1	0.67
Qwen2.5	3B	8	1	PPO	1.5 ч	Sampling (t=0.5)	0.59	0.18	0.77

Итоговая модель

Таким образом, лучшее качество показала модель Qwen/Qwen2.5-3B-Instruct с 8-битной квантизацией, дообученная с LoRA. Среды выполнения Colab хватило для полного ее дообучения. BERTScore мало отличается от базовой модели, однако LLM-судья детектирует больше исследовательской ценности в генерации после fine-тюнинга на данных Лаборатории. Заметим, что в целом разница итоговых скоров среди LoRA моделей обеспечивается различием в LLM-компоненте, в то время как BERTScore отличается менее чем на 0.1. Сравнить качество моделей Qwen2.5-3B с 4-битной и Qwen2.5-7B с 8-битной квантизацией на всех стратегиях генерации не удалось, но с beam search более точная квантизация с меньшим числом параметров выигрывает.

В условиях жестких ограничений размера батча, вызванных большими текстами и небольшого объема памяти, с обучающей выборкой из 104 крупных текстов (примерно по 20 страниц каждый), fine-tuning с LoRA с точной квантизацией и выбором beam search в качестве метода генерации оказался лучшим решением.

Решение оформлено в виде Streamlit-приложения для использования с новыми текстами.

В дальнейшем исследовании открытого кодирования мы планируем стабилизировать PPO дообучение на более легких моделях (1.5B параметров) с возможностью увеличения размера батча.