

Проект “Автоматизация тематического кодирования качественных интервью в социологических исследованиях”

Постановка задачи

В рамках работы была поставлена задача автоматизации процесса качественного анализа интервью, а именно: осуществление моделью разметки текста с выделением релевантных тематических кодов в заданном формате. В качестве обучающих и тестовых данных служили анонимизированные командой тексты интервью, полученные от Лаборатории молодежных исследований НИУ ВШЭ СПб.

Поскольку предполагается использование модели с данными Лаборатории, включающими конфиденциальную информацию об участниках исследований, модель должна быть компактной, чтобы работать локально на компьютерах Лаборатории. Кроме того, ограничением при обучении стали ресурсы бесплатного Google Colab. Модель должна быть обучена на русскоязычном корпусе, т.к. ЦМИ проводит исследования только в России.

Данные для обучения

150 анонимизированных интервью из лаборатории ВШЭ СПб “Центр молодежных исследований”. Интервью собраны в рамках различных исследований лаборатории. Все интервью являются глубинными, содержащими широкий спектр вопросов о респонденте и теме исследования. Одно интервью закодировано и размечено лабораторией в соответствии с внутренними стандартами.

Более подробный анализ данных предоставлен в файле `Eda_interviews.ipynb`

23 из 150 интервью использовались для теста.

Формат данных для теста:

Input: текст интервью, тема исследования

Output: разметка в формате «общий код: цитата (конкретный код)».

Выбор базовой модели

Изначально планировалось протестировать две модели: Qwen3.5-2B и DeepSeek-R1-Distill-Qwen-7B. Однако в процессе изучения документации выяснилось, что Qwen изначально выигрывает Deepseek за счет обучения на многоязычном корпусе с хорошим покрытием русского языка. Решающим фактором выбора стало наличие открытой архитектуры и стабильная работа в Google Colab.

Командой было решено проводить эксперименты с моделями семейства Qwen: с Qwen2.5-3B-Instruct и Qwen2.5-7B-Instruct, так как Instruct модели лучше настроены на четкие ответы на вопросы.

Эксперименты с различными конфигурациями

В процессе поиска оптимальной архитектуры для задачи автоматического кодирования

интервью был проведен ряд экспериментов с моделями семейства Qwen различных размеров и конфигураций. В поисках оптимального решения мы сравнивали следующие параметры моделей и ставили следующие предположения о работе модели при выборе определенного параметра:

Количество параметров модели: 1.5B, 3B и 7B

- большее число параметров позволяет “запомнить” больше абстрактных паттернов, таких как теоретическая релевантность, поэтому такая модель может быть точнее
- однако, при использовании большего количества параметров необходимо применять более жесткую квантизацию, что делает модель потенциально хуже из-за низкой точности в весах, поэтому с учетом этого модель с меньшим количеством параметров потенциально может работать лучше
- также, даже при применении квантизации 7B модель может не поместиться в доступные 15 Гб памяти в Google Colab при дообучении

Результат: модель 1.5B с 8-битной квантизацией оказалась плохого качества при дообучении, а модель 7B при дообучении не вместились в Google Colab даже с 4-битной квантизацией. В итоге, модель 3B была использована для дообучения, а модель 7B была использована для промпт инжиниринга.

Квантизация: 4 бит и 8 бит

- более точная квантизация означает лучшую чувствительность модели к новым данным
- при использовании жесткой квантизации, модель может стать значительно менее точной

Результат: 4 бит квантизация (с вычислениями в bfloat16) стала единственной, позволяющей обучать модели с 3 миллиардами параметров и использовать модели с 7 миллиардами параметров в Google Colab.

Стратегия генерации: greedy search, beam search, доработанный beam search

- greedy search - потребляет мало памяти и работает быстро, что может быть полезно в нашей задаче
- beam search - может дать четкие, постоянные коды, что и необходимо в задаче кодирования, но работает медленнее и может повторяться
- доработанный beam search - борется с повторениями слов и строк, так как данная проблема была обнаружена при классическом beam search:
repetition_penalty=1.5 штрафует генерацию токенов, которые уже встречались
no_repeat_ngram_size=4 запрещает повторение 4-грамм (последовательностей из четырех токенов)
пост-обработка обеспечивает исключение дублирующихся строк и обрезание ответа после первого повторения
дополнительные штрафы за повторения токенов сделают ответы более структурированными, не дадут модели “забыть” форму вопроса

Результат: при решении задачи были использованы все три способа, но работали лучше всего beam search и доработанный beam search, при этом первый способ работает стабильно и без повторений при промпт инжиниринге, а при дообучении лучшим способом оказался доработанный beam search.

Метрики оценки

BERTScore

Для автоматической оценки семантической близости использовался BERTScore. Метрика вычисляет косинусную близость контекстуальных эмбеддингов токенов предсказанного и эталонного кодирования. Это позволяет оценивать смысловое соответствие, а не точное совпадение формулировок.

LLM Score

Для получения оценки LLM использовался вызов LLM через OpenRouter API. В качестве LLM использована openai/gpt-oss-120b как одна из самых сложных и развитых моделей среди доступных бесплатно на OpenRouter. Оценка производилась по трем параметрам:

- Релевантность (0-1): соответствие кодов содержанию интервью
- Когерентность (0-1): смысловая и структурная связанность текста
- Теоретический инсайт (0-1): глубина и концептуальная ценность кодов

Итоговая LLM-оценка вычислялась как среднее арифметическое трех параметров.

Комбинированный скор

Для итоговой оценки качества использовалась формула:

$$Combined = (BERTScore_F1 + LLM_Score)$$

Использование и дообучение моделей

Промпт-инжиниринг

Промпт инжиниринг был проведен на модели Qwen/Qwen2.5-7B-Instruct с 4-битной квантизацией, в качестве стратегии генерации использовался beam search.

Поскольку команда располагает небольшим датасетом, в качестве настройки модели использовался промпт инжиниринг, так как он заключается в ручном изменении промпта без необходимости дообучения модели. К промпту был применен ChatTemplate, чтобы отделить системный промпт от пользовательского. В базовой версии промпта (hypothesis 0), в системной части на английском языке задается роль, задача и формат ответа. В пользовательской части модели задают тему исследования и транскрипт интервью на русском языке, чтобы на основе этого модель осуществила кодирование.

Мы тестируем несколько **гипотез** по изменению этого промпта для лучшего кодирования:

- **H1:** Системный промпт на русском языке устранил языковую путаницу, что улучшит

качество модели.

- **H2:** Добавление простой последовательной инструкции для выполнения кодирования (внимательно прочитать инструкцию – прочитать текст – выделить релевантные теме исследования цитаты – подобрать для них общие и конкретные коды – дать ответ строго по формату) разобьет сложную задачу модели на более простые, что улучшит качество модели.
- **H3:** Добавление примеров готового кодирования из одного из текстов обучающей выборки даст модели еще большее “понимание” формата.

По итогам экспериментов с промпт-инжинирингом получились следующие результаты:

Промпт	BERTScore	LLM score	Total score
Base (H0)	0.721	0.761	1.482
H1	0.715	0.744	1.459
H2	0.730	0.777	1.506
H3	0.733	0.760	1.492

Промпты H2 (chain of thought) и H3 (пример готового кодирования) показали лучший результат по отношению к базовому промпту. Из-за небольшого объема тестовой выборки (23 текста) мы не проверяем статистическую значимость разницы результатов, оценивая только разницу средних скоров. Промпт H4 соединяет в себе и инструкцию, и пример кодирования – результаты получились следующие:

Промпт	BERTScore	LLM score	Total score
H4	0.726	0.786	1.512

В дальнейших исследованиях использовался промпт H4. Полный текст этого промпта, а также всех остальных, находится в приложении.

LoRA fine tuning

LoRA была проведена с моделью Qwen/Qwen2.5-3B-Instruct с 4-битной квантизацией, в качестве стратегии генерации использовались greedy search, beam search и доработанный beam search.

LoRA - это стабильный и эффективный вариант дообучения в случае, если количество примеров достаточное, что может подойти под нашу задачу.

Результаты дообучения представлены ниже:

Стратегия генерации	BERTScore	LLM score	Total score
Greedy search	0.15	0.59	0.74
Beam search	0.57	0.16	0.73
Доработанный beam search	0.66	0.30	0.96

РРО обучение с подкреплением

РРО было проведена с моделью Qwen/Qwen2.5-3B-Instruct с 4-битной квантизацией, в качестве стратегии генерации использовался greedy search.

Фреймворк РРО позволяет использовать более близкие к поставленной задаче метрики в качестве награды, влияющей на обновление весов. Кроме того, есть возможность контролировать расхождение измененной и стабильной (reference) моделями с помощью расчета KL-дивергенции и ограничения обновлений с механизмом клиппинга.

Результаты дообучения представлены ниже:

BERTScore	LLM score	Total score
0.725	0.533	1.258

Результаты

Сравнение работы модели и генерации ответа

Модель, дообученная с РРО, отвечает по формату, но цитирует примеры из промпта вместо текста и выдает одинаковые примеры. И по скорам, и по полезности самого предсказания эта модель хуже бейзлайна. Мы связываем это с тем, что, ввиду жестких ограничений по оперативной памяти, из-за которых процесс максимально “облегчили”, модель стала слишком простой для такой задачи. Поскольку для дообучения с РРО нужна не одна модель, а две, помимо добавления Flash attention, пришлось использовать реализацию Qwen2.5 с 1.5B параметров и greedy search вместо beam search.

Модель Qwen/Qwen2.5-3B-Instruct, дообученная с LoRA, показала семантически осмысленную генерацию кодов, из всех дообученных моделей наиболее похожую на референсное кодирование, которое было проведено лабораторией. Однако, модель имеет много недостатков: она меняет слова “конкретный код” и “общий код” на другие похожие слова, и через какое-то время генерации начинает галлюцинировать. Ниже мы сравним объективные метрики этой модели с другими в таблице.

Модели с использованием промпт инжиниринга показали качество лучше, чем при дообучении с LoRA, генерируя осмысленные качественные коды. При этом самым эффективным промптом оказался промпт с вложенной пошаговой инструкцией к кодированию, а также примером кодирования (промпт из Н4).

Сравнение моделей на тестовой выборке с метриками

Сравнение конфигураций на тестовой выборке (23 интервью) с подсчетом метрик показало:

Базовая модель	Количество параметров	Квантизация, бит	Размер батча	Способ дообучения	Время на обучение	Стратегия генерации	BERT Score, тест	LLM score, тест	Общий скор
----------------	-----------------------	------------------	--------------	-------------------	-------------------	---------------------	------------------	-----------------	------------

Qwen2.5	7B	4	Baseline	Baseline	Baseline	Beam search (2)	0.721	0.761	1.482
Qwen2.5	7B	4	Baseline	Baseline (prompt H1)	Baseline	Beam search (2)	0.715	0.744	1.459
Qwen2.5	7B	4	Baseline	Baseline (prompt H2)	Baseline	Beam search (2)	0.730	0.777	1.506
Qwen2.5	7B	4	Baseline	Baseline (prompt H3)	Baseline	Beam search (2)	0.733	0.760	1.492
Qwen2.5	7B	4	Baseline	Baseline (prompt H4)	Baseline	Beam search (2)	0.726	0.786	1.512
Qwen2.5	3B	4	1	LoRA	3.5 ч	Greedy search	0.15	0.59	0.74
Qwen2.5	3B	4	1	LoRA	3.5 ч	Beam search (5)	0.57	0.16	0.73

Qwen2. 5	3B	4	1	LoRA	3.5 ч	Улучше нный Beam search	0.66	0.30	0.96
Qwen2. 5	1.5B	4	1	PPO	5 ч	Greedy search	0.725	0.533	1.258

Приложение

Промпт для Н0:

“You are an expert in interview analysis. Your task is to highlight the thematic codes in the interview text and corresponding quotes.

Format of an output (consists of several general codes, each followed by quotes and specific codes):

****Общий код 1: <generate general code 1>****

"<quote text>" - **<generate specific code 1> (Конкретный код)**

"<quote text>" - **<generate specific code 2> (Конкретный код)**

****Общий код 2: <generate general code 2>****

"<quote text>" - **<generate specific code> (Конкретный код)**

****Общий код <general code number>: <generate general code>****

"<quote text>" - **<generate specific code> (Конкретный код)**

and so on. You choose the number of general and specific codes.

Now you should do the markup for the interview according to the plan. Important: The answer should contain only codes and quotes, without unnecessary words and repetitions.

The quotes must be strictly from the text. Give the answer in Russian.”

Промпт для Н1:

“Ты эксперт в анализе интервью. Твоя задача -- разметить тематические коды и выделить соответствующие цитаты

Формат вывода (состоит из нескольких общих кодов, каждый сопровождается цитатами и конкретными кодами):

****Общий код 1: <сгенерируй общий код 1>****

"<текст цитаты>" - **<сгенерируй конкретный код 1> (Конкретный код)**

"<текст цитаты>" - **<сгенерируй конкретный код 2> (Конкретный код)**

****Общий код 2: <сгенерируй общий код 2>****

"<текст цитаты>" - **<сгенерируй конкретный код> (Конкретный код)**

****Общий код <номер общего кода>: <сгенерируй общий код>****

"<текст цитаты>" - **<сгенерируй конкретный код> (Конкретный код)**

и так далее. Ты выбираешь количество общих и конкретных кодов

Теперь закодируй интервью согласно плану. Важно: ответ должен содержать только коды и цитаты, без ненужных слов и повторов.

Цитаты должны быть строго из текста. Дай ответ на русском языке”

Промпт для Н2:

“You are an expert in interview analysis. Your task is to highlight the thematic codes in the interview text and corresponding quotes.

Act step by step:

1. Carefully review the output format shown in the example below. Remember that each code block must contain "Общий код" (General code), then Quote, then "Конкретный код" (Specific code). The quote must be verbatim and enclosed in quotation marks.
2. Read the interview transcript and the topic. Identify all fragments (quotes) that relate to the interview topic.
3. Group the quotes by general themes — these will be the "Общий код" (General codes). For each general theme, come up with a short name.
4. Within each general code, identify specific meaning aspects — these will be the "конкретный код" (Specific codes). The names of specific codes should reflect the essence of the quote.
5. Generate the answer strictly following the format from the example. Do not add any explanations, do not write words like 'Step 1', 'Step 2' — only the final blocks of codes and quotes.

Format of an output (consists of several general codes, each followed by quotes and specific codes):

****Общий код 1: <generate general code 1>****

"<quote text>" - **<generate specific code 1> (Конкретный код)**

"<quote text>" - **<generate specific code 2> (Конкретный код)**

****Общий код 2: <generate general code 2>****

"<quote text>" - **<generate specific code> (Конкретный код)**

****Общий код <general code number>: <generate general code>****

"<quote text>" - **<generate specific code> (Конкретный код)**

and so on. You choose the number of general and specific codes.

Now you should do the markup for the interview according to the plan. Important: The answer should contain only codes and quotes, without unnecessary words and repetitions.

The quotes must be strictly from the text. Give the answer in Russian.”

Промпт для НЗ:

“You are an expert in interview analysis. Your task is to highlight the thematic codes in the interview text and corresponding quotes.

Format of an output (consists of several general codes, each followed by quotes and specific codes):

****Общий код 1: <generate general code 1>****

"<quote text>" - **<generate specific code 1> (Конкретный код)**

"<quote text>" - **<generate specific code 2> (Конкретный код)**

****Общий код 2: <generate general code 2>****

"<quote text>" - **<generate specific code> (Конкретный код)**

****Общий код <general code number>: <generate general code>****

"<quote text>" - **<generate specific code> (Конкретный код)**

and so on. You choose the number of general and specific codes.

Example of a topic:

ПОКОЛЕНЧЕСКАЯ ИДЕНТИЧНОСТЬ, ЖИЗНЕННЫЕ ВЫБОРЫ И УСТОЙЧИВОСТЬ
РОССИЙСКОЙ МОЛОДЕЖИ

Example of a general code related to the topic (pay attention to the structure):

****Общий код 1: Поколенческие характеристики, ценности и жизненные ориентиры****

"Мне кажется, большинство особо не стремятся там вот срочно, прямо сейчас там жениться, замуж, там детей и так далее. Вот. То есть как-то больше сосредоточены даже не на карьере, а на себе, на том, чтобы сложить все для себя вот так, как хочется, да. То есть не просто чтобы

там выйти замуж, а чтобы выйти замуж вот по любви, чтобы все было идеально. Вот на какой-то такой идеальности что ли." - **Фокус на самореализации и качественных отношениях (конкретный код)**

"У нашего поколения все-таки все по-другому. Нам не дадут квартиру просто так. Нам не обязательно так просто получить место там где-то на работе и так далее, да. Но при этом у нас гораздо больше возможностей в плане, как сказать, чему-то научиться новому, куда-то поехать, что-то посмотреть, составить свое мнение, там высказать свое мнение даже." - **Осознание свободы выбора и новых возможностей (конкретный код)**

"У детей нынешних у них как будто меньше табу что ли. [...] они спокойно со мной могла поговорить на какие-то откровенные темы, которые мне в ее возрасте, я тоже задумывалась об этом, у меня тоже было какое-то мнение, но я боялась об этом говорить со взрослыми, потому что это было табуировано. [...] Поэтому у них мне кажется растет какое-то более свободное поколение что ли." - **Сравнение с младшим поколением: свобода от табу (конкретный код)**

"Мне кажется, что поколение у нас достаточно трудолюбивое при этом как бы. То есть если человек чего-то хочет добиться в карьерной сфере, ну, человек действительно может приложить там все усилия и добиться этого. Вот. Потому что возможностей супер много сейчас." - **Трудолюбие и вера в возможности (конкретный код)**

Now you should do the markup for the interview according to the plan. Important: The answer should contain only codes and quotes, without unnecessary words and repetitions.

The quotes must be strictly from the text. Give the answer in Russian.”

Промпт для Н4:

“You are an expert in interview analysis. Your task is to highlight the thematic codes in the interview text and corresponding quotes.

Act step by step:

1. Carefully review the output format shown in the example below. Remember that each code block must contain "Общий код" (General code), then Quote, then "Конкретный код" (Specific code). The quote must be verbatim and enclosed in quotation marks.
2. Read the interview transcript and the topic. Identify all fragments (quotes) that relate to the interview topic.
3. Group the quotes by general themes — these will be the "Общий код" (General codes). For each general theme, come up with a short name.
4. Within each general code, identify specific meaning aspects — these will be the "конкретный код" (Specific codes). The names of specific codes should reflect the essence of the quote.

5. Generate the answer strictly following the format from the example. Do not add any explanations, do not write words like 'Step 1', 'Step 2' — only the final blocks of codes and quotes.

Format of an output (consists of several general codes, each followed by quotes and specific codes):

****Общий код 1: <generate general code 1>****

"<quote text>" - ****<generate specific code 1> (Конкретный код)****

"<quote text>" - ****<generate specific code 2> (Конкретный код)****

****Общий код 2: <generate general code 2>****

"<quote text>" - ****<generate specific code> (Конкретный код)****

****Общий код <general code number>: <generate general code>****

"<quote text>" - ****<generate specific code> (Конкретный код)****

and so on. You choose the number of general and specific codes.

Example of a topic:

ПОКОЛЕНЧЕСКАЯ ИДЕНТИЧНОСТЬ, ЖИЗНЕННЫЕ ВЫБОРЫ И УСТОЙЧИВОСТЬ
РОССИЙСКОЙ МОЛОДЕЖИ

Example of a general code related to the topic (pay attention to the structure):

****Общий код 1: Поколенческие характеристики, ценности и жизненные ориентиры****

"Мне кажется, большинство особо не стремятся там вот срочно, прямо сейчас там жениться, замуж, там детей и так далее. Вот. То есть как-то больше сосредоточены даже не на карьере, а на себе, на том, чтобы сложить все для себя вот так, как хочется, да. То есть не просто чтобы там выйти замуж, а чтобы выйти замуж вот по любви, чтобы все было идеально. Вот на какой-то такой идеальности что ли." - ****Фокус на самореализации и качественных отношениях (конкретный код)****

"У нашего поколения все-таки все по-другому. Нам не дадут квартиру просто так. Нам не обязательно так просто получить место там где-то на работе и так далее, да. Но при этом у нас гораздо больше возможностей в плане, как сказать, чему-то научиться новому, куда-то поехать, что-то посмотреть, составить свое мнение, там высказать свое мнение даже." - ****Осознание свободы выбора и новых возможностей (конкретный код)****

"У детей нынешних у них как будто меньше табу что ли. [...] они спокойно со мной могла поговорить на какие-то откровенные темы, которые мне в ее возрасте, я тоже задумывалась об этом, у меня тоже было какое-то мнение, но я боялась об этом говорить со взрослыми, потому что это было табуировано. [...] Поэтому у них мне кажется растет какое-то более свободное

поколение что ли." - ****Сравнение с младшим поколением: свобода от табу (конкретный код)****

"Мне кажется, что поколение у нас достаточно трудолюбивое при этом как бы. То есть если человек чего-то хочет добиться в карьерной сфере, ну, человек действительно может приложить там все усилия и добиться этого. Вот. Потому что возможностей супер много сейчас." - ****Трудолюбие и вера в возможности (конкретный код)****

Now you should do the markup for the interview according to the plan. Important: The answer should contain only codes and quotes, without unnecessary words and repetitions.

The quotes must be strictly from the text. Give the answer in Russian.”