

Постановка задачи

В рамках работы была поставлена задача автоматизации процесса качественного анализа интервью, а именно: осуществление моделью разметки текста с выделением релевантных тематических кодов в заданном формате. В качестве обучающих и тестовых данных служили анонимизированные командой тексты интервью, полученные от Лаборатории молодежных исследований НИУ ВШЭ СПб.

Формат данных для теста:

Input: текст интервью, тема исследования

Output: разметка в формате «общий код: цитата - конкретный код».

Выбор базовой модели

Изначально планировалось протестировать две модели: Qwen3.5-2B и DeepSeek-R1-Distill-Qwen-7B. Однако в процессе изучения документации и экспериментов выяснилось, что Qwen изначально выигрывает Deepseek за счет обучения на многоязычном корпусе с хорошим покрытием русского языка. Решающим фактором выбора стало наличие открытой архитектуры и стабильная работа в Google Colab.

Командой было решено проводить эксперименты с моделями семейства Qwen, преимущественно с Qwen2.5-3B-Instruct.

Эксперименты с различными конфигурациями

В процессе поиска оптимальной архитектуры для задачи автоматического кодирования интервью был проведен ряд экспериментов с моделями семейства Qwen различных размеров и конфигураций. Ниже представлено описание каждого эксперимента.

Модель Qwen2.5-1.5B с LoRA

Цель эксперимента: проверить возможность использования компактной модели для экономии ресурсов GPU и потенциального увеличения batch size.

Конфигурация:

- Базовая модель: Qwen/Qwen2.5-1.5B-Instruct
- Метод дообучения: LoRA ($r=16$, $\alpha=32$)
- Квантизация: 4-bit (nf4)
- Batch size: 2
- Максимальная длина: 2048 токенов

Результаты

Модель не демонстрировала снижения функции потерь в процессе обучения, значения loss оставались на плато. На тестовых примерах модель преимущественно воспроизводила фрагменты исходного текста интервью вместо генерации требуемых кодов. Отсутствовало

понимание требуемого формата вывода: модель не использовала маркеры общих и конкретных кодов.

Вывод

Ёмкости модели 1.5B параметров оказалось недостаточно для освоения сложной структурированной задачи выделения тематических кодов и их привязки к цитатам. Модель воспринимала задачу как продолжение текста интервью, а не как его аналитическую обработку.

Модель Qwen2.5-3B с 4-битной квантизацией

Цель эксперимента: проверить возможность ускорения обучения за счет увеличения размера модели при сохранении 4-битной квантизации.

Конфигурация:

- Базовая модель: Qwen/Qwen2.5-3B-Instruct
- Квантизация: 4-bit (nf4)
- Batch size: 2
- Gradient checkpointing: включён

Результаты

Обучение оказалось невозможным из-за переполнения памяти GPU T4 (16 ГБ). Даже с включенным gradient checkpointing и оптимизациями памяти, потребление видеопамати превышало доступный объём.

Вывод

3B модель в 4-битной квантизации занимает около 10-11 ГБ, добавление batch size 2 удваивает потребление памяти для активаций и градиентов, что превышает лимиты Google Colab.

Модель Qwen2.5-3B с 8-битной квантизацией и batch size 1

Цель эксперимента: оценить влияние 8-битной квантизации на качество обучения при использовании batch size 1.

Конфигурация:

- Базовая модель: Qwen/Qwen2.5-3B-Instruct
- Квантизация: 8-bit (bitsandbytes)
- Batch size: 1
- Gradient accumulation steps: 8

Результаты

Модель успешно загружалась и обучалась без ошибок памяти. Значение функции потерь практически не уменьшалось в процессе обучения. *Генерация на тестовых данных представляла собой преимущественно несвязный текст с нарушенной грамматикой. Модель не выделяла коды в требуемом формате, ответы содержали случайные символы.*

Вывод

8-битная квантизация приводит к более существенной потере точности весов по сравнению с 4-битной (особенно для формата nf4, оптимизированного для нормальных распределений). *Для задачи, требующей тонкого семантического понимания русскоязычных текстов, потеря точности оказалась критичной.*

Модель Qwen2.5-7B с LoRA

Цель эксперимента: оценить потенциал более мощной 7B модели для улучшения качества кодирования.

Конфигурация:

- Базовая модель: Qwen/Qwen2.5-7B-Instruct
- Метод дообучения: LoRA ($r=16$, $\alpha=32$)
- Квантизация: 4-bit (nf4)
- Batch size: 1
- Gradient accumulation steps: 8

Результаты

Модель успешно загружалась в память (около 14 ГБ). В процессе обучения loss стабильно снижался. Однако при тестировании модель *генерировала практически идентичные ответы для разных входных интервью*. Также, наблюдалась сильная склонность к повторению одних и тех же общих кодов независимо от содержания интервью.

Вывод

Несмотря на большой размер, 7B модель с LoRA адаптерами продемонстрировала недостаточную способность к обобщению. Вероятно, при данном объеме обучающих данных и параметрах LoRA, адаптеры не успевают настроиться на специфику задачи, а модель полагается на свои предобученные паттерны, что приводит к однотипным ответам.

Эксперимент с PPO Trainer

Цель эксперимента: проверить возможность использования методов обучения с подкреплением для улучшения качества генерации кодов.

Конфигурация:

- Базовая модель: Qwen/Qwen2.5-3B-Instruct
- Метод: PPO (Proximal Policy Optimization) через TRL
- Функция награды: комбинация BERTScore и LLM score
- Квантизация: 4-bit
- Batch size: 2

Результаты

Модель показала крайне *нестабильное обучение*: loss часто расходился после нескольких шагов. Также у данного способа оказались достаточно *высокие требования к памяти* из-за необходимости хранения нескольких копий модели (policy, reference, value). Настройка функции вознаграждения оказалась нетривиальной: *автоматические метрики плохо коррелировали с качеством кодирования*. Время обучения оказалось неприемлемо большим для ресурсов Colab.

Вывод

РРО требует значительно больше вычислительных ресурсов и тщательной настройки гиперпараметров. Для задачи открытого кодирования, где эталонные ответы уже размечены, использование методов обучения с подкреплением избыточно и неоправданно сложно.

Итоговая модель

В процессе экспериментов мы пришли к окончательному варианту, который показал наилучшие результаты – ***Qwen2.5-3B с 4-битной квантизацией, batch size 1 и LoRA***

Параметры:

- Базовая модель: Qwen/Qwen2.5-3B-Instruct
- Квантизация: 4-bit (nf4, double quantization)
- Batch size: 1
- Gradient accumulation steps: 8
- LoRA: $r=16$, $\alpha=32$, $\text{dropout}=0.05$
- Target modules: q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj

Обоснование выбора

3B модель обеспечивает *достаточную ёмкость* для освоения задачи при сохранении возможности работы в Colab. Заданная 4-битная квантизация с типом nf4 и double quantization дает наилучшее соотношение *точности* и памяти. Batch size 1 с накоплением градиентов 8 единственный способ обучить модель без проблемы CUDA Out of Memory за счет имитирования обработки 8 примеров за одну итерацию при фактическом использовании памяти только для одного примера. LoRA с $r=16$ обеспечивает достаточную *гибкость адаптации при малом количестве обучаемых параметров* (около 30 млн).

Оптимальной была признана следующая конфигурация:

- Базовая модель: Qwen/Qwen2.5-3B-Instruct
- Квантизация: 4-bit (библиотека bitsandbytes, тип nf4)
- Метод дообучения: LoRA
- Параметры LoRA: $r=16$, $\alpha=32$, $\text{dropout}=0.05$
- Target modules: q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj
- Batch size: 1
- Gradient accumulation steps: 8
- Learning rate: $2e-4$
- Максимальная длина: 2048 токенов

Данные параметры были выбраны как оптимальный баланс между качеством обучения и ограничениями по памяти Google Colab. 4-битная квантизация позволяет загрузить 3B модель с LoRA адаптерами, используя около 12-13 ГБ видеопамяти, что оставляет небольшой запас для вычислений. Gradient accumulation steps компенсирует малый физический размер батча.

Метрики оценки

BERTScore

Для автоматической оценки семантической близости использовался BERTScore. Метрика вычисляет косинусную близость контекстуальных эмбеддингов токенов предсказанного и эталонного кодирования. Это позволяет оценивать смысловое соответствие, а не точное совпадение формулировок.

LLM-ассистент для экспертной оценки

Для получения экспертной оценки использовался вызов LLM через OpenRouter API. Оценка производилась по трем параметрам:

- Релевантность (1-5): соответствие кодов содержанию интервью
- Когерентность (1-5): грамматическая и стилистическая корректность
- Теоретический инсайт (1-5): глубина и концептуальная ценность кодов

Итоговая LLM-оценка вычислялась как среднее арифметическое трех параметров.

Комбинированный скор

Для интегральной оценки качества использовалась формула:

$$Combined = (BERTScore_F1 + LLM_Score/5) / 2$$

Проблема повторений в генерации на тесте

В процессе тестирования обученной модели была выявлена критическая проблема: при использовании стандартных Beam Search и Greedy Search модель часто за цикливалась, повторяя одни и те же цитаты и коды многократно. Это делало результаты генерации непригодными для практического использования.

Тестирование стандартных стратегий

При оценке на тестовых данных были получены следующие результаты.

Greedy Search:

- BERTScore F1: 0.677111
- LLM-оценка: 3.777778 / 5
- Проблема повторения фрагментов, неполная разметка

Beam Search

- BERTScore F1: 0.717551
- LLM-оценка: 3.777778 / 5

- Проблема заикливания на определенных паттернах

Разработка стратегии «генерация без повторений»

Для решения проблемы была разработана модифицированная стратегия, основанная на Beam Search, но дополненная механизмами борьбы с повторениями:

- Beam Search (num_beams=5) как основа обеспечивает поиск наиболее вероятной последовательности
- repetition_penalty=1.5 штрафует генерацию токенов, которые уже встречались
- no_repeat_ngram_size=4 запрещает повторение 4-грамм (последовательностей из четырёх токенов)
- Пост-обработка обеспечивает исключение дублирующихся строк и обрезание ответа после первого повторения

Такая комбинация позволила сохранить преимущества многолучевого поиска (стабильность, информативность) при одновременном подавлении повторения, которое было характерно для чистых стратегий.

Такая стратегия показала следующие результаты:

- BERTScore F1: 0.719774
- LLM-оценка: 3.222222 / 5

Результаты

Поскольку большинство моделей не выдавали осмысленный текст, значение имеет только сравнение метрик для различных способов генерации модели с 3B параметрами и 4-битной квантизацией, обученной с LoRA.

Сравнение стратегий генерации на тестовой выборке (3 интервью) показало:

Базовая модель	Количество параметров	Квантизация, бит	Размер батча	Способ дообучения	Время на обучение	Стратегия генерации	BERTS core, тест	LLM score, тест
Qwen2.5	3B	4	1	LoRA	1.5 ч	Greedy search	0.67	3.78
Qwen2.5	3B	4	1	LoRA	1.5 ч	Beam search (5)	0.71	3.78
Qwen2.5	3B	4	1	LoRA	1.5 ч	Улучшенный Beam search	0.72	3.22

Несмотря на то, что *Beam Search* демонстрирует высокие количественные показатели, его практическое применение ограничено проблемой повторений. Стратегия *without_repetition*, основанная на Beam Search с добавлением штрафов за повторения (`repetition_penalty=1.5`, `no_repeat_ngram_size=4`) и пост-обработкой, позволяет получить результат в заданном формате без лишних повторений, сохраняя при этом высокое качество кодирования. Таким образом, данная стратегия является оптимальным выбором для автоматической разметки интервью.

Заключение

В ходе работы была обучена модель для автоматического кодирования интервью на русском языке. Оптимальной конфигурацией признана Qwen2.5-3B-Instruct с 4-битной квантизацией и LoRA-дообучением. Разработана специализированная стратегия генерации «без повторений», основанная на Beam Search с добавлением штрафов за повторения и пост-обработкой. Данная стратегия позволила устранить проблему заикливания, характерную для стандартных методов, и получить стабильные, информативные коды.

Дальнейшее улучшение качества может быть достигнуто за счёт увеличения объёма размеченных данных и экспериментов с параметрами LoRA.